



UNIVERSIDADE FEDERAL DE MATO GROSSO
PRÓ-REITORIA DE PESQUISA
PROGRAMA INSTITUCIONAL DE INICIAÇÃO CIENTÍFICA

FORMULÁRIO DE APRESENTAÇÃO

Iniciação
Científica
UFMT

2019/2020

Título do projeto de pesquisa:	MODELAGEM DE ECOSISTEMAS TROPICAIS		
Título do plano de trabalho:	REDUÇÃO DE DIMENSIONALIDADE EM DINÂMICA DE FLUIDOS TURBULENTOS PARA MODELAGEM AMBIENTAL		
Modalidade:	PIBIC		
Ciclo/Vigência:	2025–2026		
Dados do(a) aluno(a)			
Nome:	ELDO FRANCISCO CHAGAS JUNIOR	Curso:	ENGENHARIA DE CONTROLE E AUTOMAÇÃO – FA-ENG/UFMT
Campus:	CUIABÁ	Semestre:	—
E-mail:	E-MAIL A PREENCHER	Telefone:	A PREENCHER
Início da participação:	30/10/2025	Término:	A CONFIRMAR
Dados do(a) orientador(a)			
Nome:	PROFA. DRA. DANIELA DE OLIVEIRA MAIONCHI		
E-mail:	E-MAIL A PREENCHER	Telefone:	A PREENCHER
Apreciação sucinta do(a) orientador(a):			



UNIVERSIDADE FEDERAL DE MATO GROSSO
PRÓ-REITORIA DE PESQUISA
PROGRAMA INSTITUCIONAL DE INICIAÇÃO CIENTÍFICA

RELATÓRIO FINAL

MODELAGEM DE ECOSSISTEMAS TROPICAIS

**REDUÇÃO DE DIMENSIONALIDADE EM DINÂMICA DE FLUIDOS
TURBULENTOS PARA MODELAGEM AMBIENTAL**

CUIABÁ
SETEMBRO / 2026



UNIVERSIDADE FEDERAL DE MATO GROSSO
PRÓ-REITORIA DE PESQUISA
PROGRAMA INSTITUCIONAL DE INICIAÇÃO CIENTÍFICA

ELDO FRANCISCO CHAGAS JUNIOR
PIBIC
ENGENHARIA DE CONTROLE E AUTOMAÇÃO – FAENG/UFMT

MODELAGEM DE ECOSISTEMAS TROPICAIS

REDUÇÃO DE DIMENSIONALIDADE EM DINÂMICA DE FLUIDOS
TURBULENTOS PARA MODELAGEM AMBIENTAL

Relatório Final apresentado à Universidade Federal de Mato Grosso, Pró-Reitoria de Pesquisa, Programa Institucional de Bolsas/Voluntariado de Iniciação Científica, sob orientação de PROFA. DRA. DANIELA DE OLIVEIRA MAIONCHI.

CUIABÁ
SETEMBRO / 2026



UNIVERSIDADE FEDERAL DE MATO GROSSO
PRÓ-REITORIA DE PESQUISA
PROGRAMA INSTITUCIONAL DE INICIAÇÃO CIENTÍFICA

SUMÁRIO

SUMÁRIO

RESUMO	i
LISTA DE FIGURAS	ii
LISTA DE TABELAS	iii
1 INTRODUÇÃO	1
2 REVISÃO DA LITERATURA	3
2.1 Modelagem reduzida orientada por dados	3
2.2 Decomposição Ortogonal Própria	3
2.3 Autoencoder e regularização latente	4
2.4 SINDy e integração temporal	5
2.5 POD estabilizadora no espaço latente	6
2.6 Equações físicas discretizadas no OpenFOAM	7
3 METODOLOGIA	8
3.1 Percurso metodológico e correspondência com o plano	8
3.2 Casos OpenFOAM	9
3.3 Redução POD e SAE	10
3.4 Identificação e avaliação dinâmica	11
3.5 Auditoria e alinhamento	12
4 RESULTADOS E DISCUSSÃO	13
4.1 Evolução desde o relatório parcial e o artigo do CBCFD	13
4.2 Representação por POD	13
4.3 Representação por SAE	15
4.4 Dinâmica identificada por SINDy	16
4.5 POD como estabilizador latente	17
4.6 Auditoria da cavidade e validação corrigida	19
4.7 Síntese científica	19
5 CONCLUSÃO	20



UNIVERSIDADE FEDERAL DE MATO GROSSO
PRÓ-REITORIA DE PESQUISA
PROGRAMA INSTITUCIONAL DE INICIAÇÃO CIENTÍFICA

6	DIFICULDADES ENCONTRADAS	22
7	REFERÊNCIAS BIBLIOGRÁFICAS	23
8	PRODUTOS GERADOS	25



RESUMO

Simulações de escoamentos turbulentos e multifásicos geram grandes volumes de dados, cuja alta dimensionalidade dificulta o armazenamento, a interpretação dos fenômenos e a construção de modelos preditivos. Nesse contexto, o presente trabalho, desenvolvido no âmbito do plano *Redução de Dimensionalidade em Dinâmica de Fluidos Turbulentos para Modelagem Ambiental* e vinculado ao projeto *Modelagem de ecossistemas tropicais*, investigou métodos orientados por dados para obter representações compactas e identificar equações diferenciais reduzidas a partir de campos calculados por dinâmica dos fluidos computacional. A pesquisa envolveu revisão bibliográfica, capacitação no OpenFOAM e em bibliotecas Python, geração e organização de snapshots, redução dimensional por decomposição ortogonal própria (POD) e autoencoder (SAE) e identificação dinâmica pelo método SINDy. Inicialmente, o fluxo de trabalho foi validado em geometrias simplificadas, e os resultados de POD e SAE para o caso cavity deram origem a um artigo publicado no congresso CBCFD. Na etapa final, a análise foi ampliada para três configurações de ruptura de barragem—laminar, URANS $k-\omega$ SST e LES-WALE—e para uma cavidade URANS, comparando-se as arquiteturas POD-SINDy, SAE-SINDy e SAE-POD-SINDy. Embora POD e SAE tenham apresentado capacidade de reconstruir os campos, os modelos SINDy aplicados diretamente às respectivas coordenadas reduzidas foram, em geral, instáveis durante a integração livre. Em contrapartida, a aplicação da POD ao espaço latente do autoencoder permitiu completar a integração nos quatro casos, com erros relativos entre 0,551 e 0,858 e valores de R^2 entre 0,264 e 0,697. Esses resultados indicam melhora no condicionamento e na estabilidade, mas mostram que os modelos ainda não possuem fidelidade suficiente para substituir as simulações CFD. Além da comparação entre os métodos, a auditoria dos dados permitiu identificar e corrigir inconsistências nos campos e no alinhamento temporal do caso cavity. Como continuidade, o pipeline desenvolvido será aplicado aos escoamentos microfluídicos controlados por microválvulas Tesla já simulados no OpenFOAM. Nessa nova etapa, pretende-se reduzir os campos de pressão e velocidade, identificar a dinâmica dos escoamentos direto e reverso e apoiar análises paramétricas envolvendo número de Reynolds, geometria e diodicidade. Em síntese, a pesquisa estabeleceu e avaliou criticamente uma metodologia integrada de redução dimensional e identificação dinâmica, fornecendo uma base para aplicações futuras e evidenciando a necessidade de distinguir qualidade de reconstrução de capacidade de previsão autônoma.

Palavras-chave: OpenFOAM; redução dimensional; POD; SAE; SINDy; microfluídica.



UNIVERSIDADE FEDERAL DE MATO GROSSO
PRÓ-REITORIA DE PESQUISA
PROGRAMA INSTITUCIONAL DE INICIAÇÃO CIENTÍFICA

LISTA DE FIGURAS

LISTA DE FIGURAS

1	Fluxo de trabalho para preparação dos casos e pós-processamento no OpenFOAM, empregado no relatório parcial e no artigo do CBCFD. . .	8
2	Energia e erro POD. Na cavidade usa-se a reexecução corrigida; nos dam-break permanecem as ressalvas de canais.	14
3	Primeiro modo POD multivariável.	15
4	Comparação do R^2 de reconstrução dos SAE. O LES corresponde à configuração corrigida; seus SINDy salvos ainda usam o latente antigo.	16
5	Erro relativo e R^2 da integração livre SAE–POD–SINDy.	17
6	Campos decodificados pela integração livre do modelo híbrido.	18
7	Validação de campos nos casos mais desafiadores.	18



UNIVERSIDADE FEDERAL DE MATO GROSSO
PRÓ-REITORIA DE PESQUISA
PROGRAMA INSTITUCIONAL DE INICIAÇÃO CIENTÍFICA

LISTA DE TABELAS

LISTA DE TABELAS

1	Alinhamento entre etapas do plano de trabalho e execução final.	9
2	Casos de alta fidelidade analisados.	10
3	Síntese dos resultados POD com 50 modos.	14
4	Síntese dos SAE usados ou corrigidos.	15
5	Comparação dinâmica dos modelos SINDy.	17



1. INTRODUÇÃO

Equações de conservação de massa, quantidade de movimento e energia sustentam a modelagem de escoamentos, mas sua discretização pode produzir estados com milhares ou milhões de graus de liberdade [16, 20]. Em dinâmica dos fluidos computacional (CFD), cada instante reúne campos definidos em toda a malha; a sequência desses campos aumenta o custo de armazenamento, análise e construção de modelos preditivos. Métodos orientados por dados podem complementar a simulação ao procurar descrições compactas para esses estados [1, 11].

Este trabalho considera três métodos. A decomposição ortogonal própria (POD) representa os campos em uma base linear; o autoencoder (SAE) aprende uma transformação não linear entre o campo e um espaço latente; e o SINDy procura uma equação diferencial esparsa para a evolução das coordenadas reduzidas [19, 6, 2]. A fundamentação, as equações e as limitações de cada método são desenvolvidas na revisão da literatura.

A motivação do plano *Redução de Dimensionalidade em Dinâmica de Fluidos Turbulentos para Modelagem Ambiental*, vinculado ao projeto institucional *Modelagem de ecossistemas tropicais*, foi avaliar essa cadeia metodológica antes de sua aplicação a sistemas ambientais complexos. A literatura registra o uso de identificação esparsa em variáveis atmosféricas e climáticas [4, 17, 22]; neste relatório, porém, a relação com a modelagem ambiental é metodológica, e os testes são realizados em geometrias controladas de menor custo e maior interpretabilidade.

O objetivo geral aprovado foi simular escoamentos com CFD e aplicar POD, SAE e SINDy para redução de dimensionalidade e regressão esparsa, contribuindo para o aperfeiçoamento e a compreensão desses métodos em fluxos turbulentos. Como objetivos específicos, foram previstos: revisar CFD, turbulência e abordagens orientadas por dados; adquirir domínio prático do OpenFOAM e de bibliotecas Python; executar tutoriais e estudos de caso; desenvolver um autoencoder para uma geometria simplificada; extrair variáveis latentes relevantes; e buscar representações analíticas da dinâmica. Também foram propostas construção e validação de um modelo reduzido, análise paramétrica, interpretação física das equações e divulgação científica.

A execução seguiu essa progressão. O relatório parcial registrou a formação nas ferramentas e os primeiros ensaios em cavity e damBreakLaminarFine. Em seguida, um conjunto da cavity com 1001 snapshots de velocidade permitiu comparar POD e SAE e originou artigo publicado no congresso CBCFD. A etapa final ampliou o estudo para três rupturas de barragem com diferentes tratamentos do momento—



laminar, URANS $k-\omega$ SST e LES–WALE—e uma cavidade com tampa móvel e URANS. Nesses quatro bancos de prova foram avaliadas as arquiteturas POD–SINDy, SAE–SINDy e SAE–POD–SINDy, incluindo reconstrução, ajuste das derivadas e integração temporal livre.

A distinção entre representação e dinâmica orienta a análise: reconstruir um snapshot com baixo erro não demonstra que o estado futuro possa ser previsto a partir de uma condição inicial. Por isso, integração livre, sem realimentação pelos estados verdadeiros, foi adotada como critério principal para captura dinâmica. A auditoria de campos, tempos e artefatos também passou a integrar a metodologia, pois canais ausentes, escalas incompatíveis ou alinhamento temporal incorreto podem produzir métricas aparentemente favoráveis sem validade física.

A continuidade definida para o projeto é a aplicação desse pipeline aos dados do trabalho *Modelagem computacional de escoamentos microfluídicos controlados por microválvulas Tesla* [21]. Nesse estudo precedente, o OpenFOAM foi empregado para simular escoamento incompressível nos sentidos direto e reverso, com os solvers icoFoam e simpleFoam; os campos de pressão e velocidade permitiram caracterizar zonas de recirculação, perda de carga e diodicidade. A válvula Tesla é um dispositivo passivo, sem partes móveis, cuja geometria oferece menor resistência em um sentido e maior resistência no sentido oposto. Essa assimetria torna o problema apropriado para investigar como coordenadas reduzidas respondem à direção do fluxo, ao número de Reynolds, à disposição de múltiplos estágios e às mudanças geométricas.

Na etapa futura, snapshots de U e p das microválvulas serão organizados de forma consistente para: comparar a compactação por POD e SAE; identificar modelos SINDy para a evolução das coordenadas reduzidas; verificar se um mesmo modelo descreve os dois sentidos de escoamento ou se modelos condicionados são necessários; e relacionar modos e variáveis latentes com recirculação, queda de pressão e diodicidade. Antes disso, deverão ser atendidas as limitações já reconhecidas no estudo das válvulas, especialmente convergência ao regime de interesse, balanço de massa, qualidade e independência de malha e equivalência das condições usadas na comparação direto–reverso. Assim, as microválvulas Tesla constituem uma transferência concreta da metodologia desenvolvida neste relatório para uma geometria aplicada e parametrizável, sem serem apresentadas como resultado já concluído do presente ciclo.



2. REVISÃO DA LITERATURA

2.1 Modelagem reduzida orientada por dados

Um modelo de ordem reduzida separa duas operações que não devem ser confundidas: representar um estado de alta dimensão por poucas coordenadas e descrever como essas coordenadas evoluem no tempo. POD e autoencoders realizam principalmente a primeira operação; SINDy procura realizar a segunda. Essa distinção é central porque um campo pode ser reconstruído com baixo erro sem que as coordenadas formem um sistema dinâmico fechado, estável ou generalizável [1, 11].

Em aplicações ambientais, séries temporais podem combinar múltiplas escalas, ruído, não linearidade e forte dependência da variável observada. A identificação esparsa já foi aplicada à oscilação Madden–Julian, à previsão de temperatura e umidade e à dinâmica de trajetória e intensidade de ciclones tropicais [4, 17, 22]. Para o presente trabalho, esses exemplos não servem como comprovação de desempenho, mas como base para três exigências transferíveis: organizar corretamente as séries temporais, escolher variáveis representativas e validar a evolução fora dos dados usados no ajuste. Os casos cavity e dam-break funcionam, portanto, como bancos de prova da metodologia antes de uma aplicação ambiental.

2.2 Decomposição Ortogonal Própria

A POD procura estruturas espaciais coerentes ordenadas pela variância ou energia contida no conjunto de dados. Na forma baseada em snapshots, a decomposição em valores singulares fornece simultaneamente uma base ortonormal, a importância relativa dos modos e os coeficientes temporais. Por ser linear, a interpretação dos modos é direta, mas fenômenos dominados por transporte, interfaces móveis ou mudanças de regime podem exigir muitos modos para representar a solução [19, 11].

Considere m snapshots, cada um transformado em um vetor de estado $x_i \in \mathbb{R}^n$. Os campos e componentes escolhidos são concatenados em

$$X = \begin{bmatrix} x_1 & x_2 & \cdots & x_m \end{bmatrix} \in \mathbb{R}^{n \times m}, \quad \bar{x} = \frac{1}{m} \sum_{i=1}^m x_i, \quad X_c = X - \bar{x} \mathbf{1}^T. \quad (1)$$

A decomposição em valores singulares é

$$X_c = U \Sigma V^T, \quad U^T U = I, \quad \Sigma = \text{diag}(\sigma_1, \dots, \sigma_s), \quad \sigma_1 \geq \cdots \geq \sigma_s \geq 0. \quad (2)$$



Os primeiros r vetores de U formam a base POD $\Phi_r = U_{[:,1:r]}$. Para um estado $x(t)$, os coeficientes e a reconstrução são

$$a(t) = \Phi_r^T [x(t) - \bar{x}], \quad \hat{x}(t) = \bar{x} + \Phi_r a(t). \quad (3)$$

A fração de energia preservada e o erro global usados neste relatório são

$$E_r = \frac{\sum_{j=1}^r \sigma_j^2}{\sum_{j=1}^s \sigma_j^2}, \quad \varepsilon_{\text{POD}} = \frac{\|X - \hat{X}_r\|_F}{\|X\|_F}. \quad (4)$$

A POD minimiza $\|X - \hat{X}_r\|_F$ entre bases lineares ortonormais de dimensão r [19, 11]. Entretanto, estruturas dominadas por transporte podem demandar uma dimensão linear maior, limitação discutida no contexto de métodos orientados por dados em fluidos [11, 1]. É importante distinguir m , número de tempos, de r , número de modos: no LES–WALE, por exemplo, os 1001 tempos foram mantidos e cada estado foi representado por 50 coeficientes na reconstrução selecionada.

2.3 Autoencoder e regularização latente

O autoencoder substitui a projeção linear fixa por duas funções parametrizadas: o encoder comprime o campo em um vetor latente e o decoder reconstrói o campo a partir desse vetor. Essa flexibilidade permite representar variedades não lineares, mas introduz dependência da arquitetura, da normalização, do processo de treinamento e da distribuição dos dados. Além disso, boa reconstrução não impõe unicidade, suavidade temporal ou fechamento dinâmico às coordenadas latentes [6, 1].

Antes do treinamento, cada característica j é normalizada usando somente o conjunto de treino:

$$\tilde{x}_{ij} = \text{clip} \left(\frac{x_{ij} - \mu_j}{\max(\sigma_j, \sigma_{\min})}, -c, c \right), \quad (5)$$

onde μ_j e σ_j são média e desvio padrão de treino, $\sigma_{\min}$ evita divisão por valores quase nulos e c limita valores extremos. O encoder e o decoder densos são composições de camadas

$$h^{(\ell)} = \rho(W^{(\ell)} h^{(\ell-1)} + b^{(\ell)}), \quad z = f_\theta(\tilde{x}), \quad \hat{x} = g_\phi(z), \quad (6)$$

em que ρ é, em geral, ReLU e $z \in \mathbb{R}^p$ é o vetor latente. A função objetivo geral é

$$\min_{\theta, \phi} \frac{1}{m_{\text{tr}}} \sum_{i \in \text{treino}} \mathcal{L}(\tilde{x}_i, g_\phi(f_\theta(\tilde{x}_i))) + \lambda_z \frac{1}{m_{\text{tr}}} \sum_i \|z_i\|_1, \quad (7)$$

com MSE ou perda de Huber. Para um resíduo escalar e , a Huber utilizada na correção do LES é

$$H_\delta(e) = \begin{cases} \frac{1}{2}e^2, & |e| \leq \delta, \\ \delta(|e| - \frac{1}{2}\delta), & |e| > \delta. \end{cases} \quad (8)$$

A penalização L_1 favorece ativações latentes esparsas quando $\lambda_z > 0$. Na execução corrigida do LES, $\lambda_z = 0$ para estabilizar primeiro a reconstrução; portanto, apesar da denominação histórica SAE, essa execução específica é matematicamente um auto-encoder denso sem penalização de esparsidade ativa. Em princípio, a variedade não linear pode ser mais compacta que um subespaço POD [6], mas as coordenadas não são únicas nem automaticamente adequadas a uma equação diferencial simples.

2.4 SINDy e integração temporal

O SINDy parte da hipótese de que a dinâmica pode ser descrita por poucos termos ativos dentro de uma biblioteca maior de funções candidatas. Em vez de ajustar diretamente uma caixa-preta, estima-se um sistema diferencial explícito cujos coeficientes e termos podem ser examinados. A parcimônia reduz a complexidade, mas o resultado depende da qualidade das derivadas, das escalas, da biblioteca e do algoritmo de regressão [2, 9].

A formulação também pode ser estendida à descoberta de equações em dados espaço-temporais, à incorporação de conhecimento físico, à análise de sensibilidade e ao controle no regime de poucos dados [18, 3, 13, 8]. Modelos substitutos em outros domínios reforçam a importância de avaliar generalização, e não somente ajuste [5]. Neste estudo, essas contribuições fundamentam a seleção parcimoniosa da biblioteca e, principalmente, a exigência de integração livre.

Seja $q(t) \in \mathbb{R}^r$ o estado reduzido, que pode ser $a(t)$ da POD, $z(t)$ do autoencoder ou uma coordenada POD latente. A matriz de estados e sua derivada são

$$Q = \begin{bmatrix} q(t_1)^T \\ \vdots \\ q(t_m)^T \end{bmatrix}, \quad \dot{Q} = \begin{bmatrix} \dot{q}(t_1)^T \\ \vdots \\ \dot{q}(t_m)^T \end{bmatrix}. \quad (9)$$

SINDy constrói uma biblioteca candidata, por exemplo,

$$\Theta(Q, t) = \begin{bmatrix} \mathbf{1} & Q & Q^{(2)} & \dots & t & t^2 & \sin(\omega t) & \cos(\omega t) \end{bmatrix}, \quad \dot{Q} \approx \Theta(Q, t)\Xi, \quad (10)$$



onde $Q^{(2)}$ reúne produtos $q_j q_k$ e cada coluna de Ξ contém os coeficientes de uma equação. A identificação esparsa pode ser escrita como

$$\hat{\Xi} = \arg \min_{\Xi} \frac{1}{2} \|\dot{Q} - \Theta \Xi\|_F^2 + \lambda \sum_{j,k} w_{jk} |\Xi_{jk}|, \quad (11)$$

com $w_{jk} = 1$ no Lasso e pesos dependentes de uma estimativa inicial no AdaLasso. Limiarização posterior remove coeficientes pequenos. O modelo descoberto é então a equação diferencial

$$\frac{d\hat{q}}{dt} = \Theta(\hat{q}, t) \hat{\Xi}, \quad \hat{q}(t_0) = q(t_0). \quad (12)$$

Na integração livre, a solução numérica da Equação (12) usa apenas a condição inicial; na avaliação de um passo, cada avanço é reiniciado em um estado verdadeiro. Assim, erro pequeno de derivada ou de um passo não garante trajetória livre estável. A diferenciação de dados ruidosos e limitados e a escolha da biblioteca e do otimizador condicionam a identificação; por isso, implementações robustas incluem formulações integrais, ensemble, restrições e diferentes regressões esparsas [9]. Colinearidade, escalas incompatíveis e bibliotecas excessivas também podem degradar numericamente o ajuste, motivo pelo qual tais fatores foram avaliados neste trabalho.

2.5 POD estabilizadora no espaço latente

Lin, Xiao e Fang [10] propõem aplicar POD aos latentes antes do SINDy. Organizando os latentes por linhas em $Z \in \mathbb{R}^{m \times p}$,

$$Z_n = (Z - \mu_z) D_z^{-1}, \quad Z_n = U_z \Sigma_z V_z^T, \quad Q = Z_n V_{z,r}, \quad (13)$$

onde $D_z = \text{diag}(\sigma_z)$ e $V_{z,r}$ contém as primeiras direções latentes. Depois da integração SINDy,

$$\hat{Z}_n = \hat{Q} V_{z,r}^T, \quad \hat{Z} = \hat{Z}_n D_z + \mu_z, \quad \hat{X} = g_\phi(\hat{Z}). \quad (14)$$

A transformação centraliza, normaliza, ortogonaliza e ordena as coordenadas. Se $r = p$, ela atua principalmente como rotação condicionadora; se $r < p$, também filtra direções de menor energia. Este trabalho separa essas duas interpretações.



2.6 Equações físicas discretizadas no OpenFOAM

Para um escoamento incompressível, as equações básicas de conservação de massa e quantidade de movimento são [16, 20]

$$\nabla \cdot u = 0, \quad \frac{\partial u}{\partial t} + (u \cdot \nabla)u = -\frac{1}{\rho} \nabla p + \nabla \cdot [2\nu_{\text{ef}} S(u)] + g, \quad S(u) = \frac{1}{2} (\nabla u + \nabla u^T). \quad (15)$$

Nos dam-break, o método VOF transporta a fração volumétrica de água α :

$$\frac{\partial \alpha}{\partial t} + \nabla \cdot (\alpha u) + \nabla \cdot [\alpha(1 - \alpha)u_c] = 0, \quad \rho = \alpha \rho_{\text{água}} + (1 - \alpha) \rho_{\text{ar}}, \quad (16)$$

em que u_c representa a compressão numérica da interface [7]. No regime laminar, $\nu_{\text{ef}} = \nu$. Em URANS, decompõe-se $u = \bar{u} + u'$ e modela-se o efeito médio de $-\overline{u'u'}$ por uma viscosidade turbulenta, de modo que $\nu_{\text{ef}} = \nu + \nu_t$; neste estudo, ν_t vem do modelo $k-\omega$ SST [12]. Em LES, resolve-se o campo filtrado $\tilde{u}$ e o efeito submalha $\tau_{\text{sgs}} = \widetilde{uu} - \tilde{u}\tilde{u}$ é representado pela viscosidade WALE [14]. A cavidade usa conservação compressível de massa e momento, gás perfeito e fechamento URANS SST. Essas equações produzem os campos de alta dimensão posteriormente reduzidos; POD, SAE e SINDy não substituem a discretização CFD durante a geração dos dados. A organização dos casos, dos dicionários e dos esquemas segue a documentação do OpenFOAM, enquanto detalhes efetivos foram confirmados diretamente nos arquivos de cada caso [15].

3. METODOLOGIA

3.1 Percurso metodológico e correspondência com o plano

O trabalho seguiu o encadeamento previsto no projeto: revisão → domínio das ferramentas → geração e organização de snapshots → POD/SAE → SINDy → validação e divulgação. A Figura 1 registra o fluxo de preparação e pós-processamento empregado desde a etapa parcial.




Figura 1: Fluxo de trabalho para preparação dos casos e pós-processamento no OpenFOAM, empregado no relatório parcial e no artigo do CBCFD.

A Tabela 1 confronta o cronograma aprovado com a execução documentada. O termo “parcial” indica que houve avanço verificável, mas não conclusão de toda a abrangência originalmente proposta.



UNIVERSIDADE FEDERAL DE MATO GROSSO
PRÓ-REITORIA DE PESQUISA
PROGRAMA INSTITUCIONAL DE INICIAÇÃO CIENTÍFICA

Tabela 1: Alinhamento entre etapas do plano de trabalho e execução final.

Período previsto	Etapas	Execução e evidência	Situação
Mês 1	Revisão inicial	CFD, turbulência, OpenFOAM, POD, autoencoders e SINDy; referências incorporadas ao relatório parcial e ao presente texto.	Concluída
Meses 2–4	Formação e tutoriais	Casos pitzDaily, damBreakLaminarFine, movingCone e aerofoil; prática com malha, dicionários, execução e ParaView.	Concluída
Meses 5–7	Simulação e dados	Casos simplificados cavity e dam-break; padronização de snapshots; primeiros POD e SAE; entrega do relatório parcial.	Concluída
Meses 8–9	Modelos reduzidos	Comparação POD/SAE e ampliação progressiva para os regimes laminar, URANS e LES.	Concluída
Meses 10–11	Identificação e interpretação	POD–SINDy, SAE–SINDy e SAE–POD–SINDy; integração livre, auditoria de proveniência e validação direta da cavity.	Concluída
Meses 10–11	Análise paramétrica	Comparação qualitativa dos fechamentos laminar, SST e WALE; sem varredura controlada de Reynolds, geometria ou condições de contorno.	Parcial
Meses 8–11	Substituto no OpenFOAM	Equações reduzidas identificadas e campos reconstruídos, mas sem implementação de um novo modelo/solver validado no OpenFOAM.	Parcial
Mês 12	Relatório e divulgação	Quatro relatórios técnicos, relatório final consolidado e artigo de congresso.	Concluída

Essa sequência também explica a mudança de escala dos dados. O artigo do CBCFD documenta uma prova de conceito da cavity com 1001 snapshots e estado formado apenas por U_x, U_y . A análise final não substitui retroativamente aquele experimento: ela amplia e audita o caso, usando 5645 snapshots válidos e U_x, U_y, p, T, k . Por isso, as métricas das duas etapas são apresentadas separadamente.

3.2 Casos OpenFOAM

A Tabela 2 alinha as configurações centrais. Os casos dam-break têm 2268 células e duração de 1 s; a cavidade tem 1600 células e duração de 5 s. Os dicionários controlDict, fvSchemes, fvSolution, transporte e propriedades foram auditados diretamente.



UNIVERSIDADE FEDERAL DE MATO GROSSO
PRÓ-REITORIA DE PESQUISA
PROGRAMA INSTITUCIONAL DE INICIAÇÃO CIENTÍFICA

Tabela 2: Casos de alta fidelidade analisados.

Caso	Solver/modelo	Malha	Tempo	Observações
Dam-break laminar	incompressibleVoF, laminar	2268, quase 2D	0–1 s; $\Delta t = 10^{-4}$	10001 saídas
Dam-break URANS	incompressibleVoF, SST	2268, quase 2D	0–1 s; $\Delta t = 10^{-4}$	10001 saídas
Dam-break LES	incompressibleVoF, WALE	2268, quase 2D	0–1 s; $\Delta t = 10^{-4}$	1001 saídas; gravação a cada 10^{-3} s
Cavity URANS	fluid, gás perfeito, SST	$40 \times 40 \times 1$	0–5 s; $\Delta t = 5 \times 10^{-4}$	5646 diretórios presentes

Todos empregam Euler de primeira ordem no tempo. Os dam-break usam PIMPLE e MULES; a cavidade usa PIMPLE com tampa a 1 m s^{-1} . A ausência de adaptação efetiva do passo e de estudos de independência de malha constitui limitação comum.

No LES–WALE, a contagem foi verificada diretamente: existem 1001 diretórios temporais, de $t = 0$ a 1 s, uniformemente separados por 10^{-3} s. O `controlDict` usa $\Delta t = 10^{-4}$ s e `writeInterval=0,001` s; portanto, são executados aproximadamente 10000 passos numéricos e armazenados 1001 estados, incluindo os extremos. Não ocorreu redução posterior de 10001 para 1001 snapshots na POD: os arquivos POD e POD–SINDy contêm todos os 1001 tempos. A subamostragem adicional ocorreu somente na cadeia SAE legada, que usou `stride=10` e 101 estados; o SAE corrigido usa `stride=1`, isto é, os 1001 snapshots disponíveis.

3.3 Redução POD e SAE

A POD seguiu as Equações (1)–(4). Cada coluna reuniu os canais físicos de um tempo; após subtrair a média temporal, a SVD forneceu modos, coeficientes e energia. Os resultados são apresentados por E_r e ε_{POD} . Na cavidade, a auditoria motivou nova execução: os canais legados α_{water} e p_{rgh} foram substituídos por p e T , e a normalização individual de cada snapshot foi removida, pois a transformação $x_i \mapsto x_i / \|x_i\|_2$ destruiria a informação de amplitude necessária à reconstrução física.

Os autoencoders usam divisão temporal, sem mistura entre passado de treino e futuro de validação, e normalização pela Equação (5). As dimensões latentes variaram de quatro a 32. A execução corrigida do LES usou camadas $11520 \rightarrow 512 \rightarrow 256 \rightarrow 128 \rightarrow 32$ no encoder e estrutura simétrica no decoder, Adam, perda Huber e $\lambda_z = 0$.



Para cada snapshot foram calculados

$$\text{MSE}_i = \frac{1}{n} \|x_i - \hat{x}_i\|_2^2, \quad \varepsilon_i = \frac{\|x_i - \hat{x}_i\|_2}{\|x_i\|_2 + \epsilon}, \quad (17)$$

e, sobre todo o conjunto,

$$R^2 = 1 - \frac{\sum_i \|x_i - \hat{x}_i\|_2^2}{\sum_i \|x_i - \bar{x}\|_2^2}. \quad (18)$$

Os artefatos efetivamente salvos foram priorizados sobre configurações apenas declaradas nos notebooks. No LES, distinguem-se o SAE legado, com 101 tempos e oito latentes, usado pelos SINDy salvos, e o SAE corrigido, com 1001 tempos e 32 latentes.

3.4 Identificação e avaliação dinâmica

Foram avaliados:

1. **POD-SINDy**: $q(t) = a(t)$ da Equação (3);
2. **SAE-SINDy**: $q(t) = z(t) = f_\theta(\tilde{x}(t))$;
3. **SAE-POD-SINDy**: $q(t)$ obtido pela Equação (13), seguido da reconstrução da Equação (14).

Após estimar $\dot{Q}$, os coeficientes foram ajustados conforme as Equações (10) e (11). O erro relativo das derivadas é

$$\varepsilon_{\dot{q}} = \frac{\|\dot{Q} - \Theta(Q, t)\hat{\Xi}\|_F}{\|\dot{Q}\|_F}. \quad (19)$$

Para uma trajetória de referência Q e uma previsão $\hat{Q}$, usaram-se

$$\varepsilon_{\text{traj}} = \frac{\|Q - \hat{Q}\|_F}{\|Q\|_F}, \quad R_{\text{traj}}^2 = 1 - \frac{\|Q - \hat{Q}\|_F^2}{\|Q - \bar{Q}\|_F^2}. \quad (20)$$

Também foram registrados erro de um passo e número de coeficientes não nulos. Na previsão de um passo, pode-se escrever esquematicamente $\hat{q}_{i+1} = q_i + \Delta t \Theta(q_i, t_i)\hat{\Xi}$; como q_i é verdadeiro a cada reinício, o erro não acumula. Já a trajetória livre resulta da integração contínua da Equação (12). Resultados de fallback guiado foram, portanto, explicitamente separados de previsão autônoma.



3.5 Auditoria e alinhamento

Foram comparados caminhos internos, hashes, dimensões, canais e tempos dos NPZ, Keras e JSON. A similaridade superior a 99% entre notebooks de casos diferentes confirmou reutilização de templates. Isso é aceitável apenas quando campos e hipóteses são adaptados. Na cavidade foi criado um validador que lê U, p, T, k diretamente do OpenFOAM e associa cada estado SINDy ao tempo físico mais próximo.



4. RESULTADOS E DISCUSSÃO

4.1 Evolução desde o relatório parcial e o artigo do CBCFD

O relatório parcial, referente ao período de 30/10/2025 a 28/02/2026, registrou a conclusão da revisão e da formação nas ferramentas e a fase final de geração dos primeiros dados. Tratava-se ainda de conjuntos exploratórios: a cavity preliminar tinha malha $120 \times 120 \times 1$ e somente 11 snapshots entre 0 e 1 s; o damBreakLaminarFine tinha cerca de 7700 células e 21 snapshots. Naquele momento, a POD já fornecia coeficientes regulares para a cavity, enquanto os SAE iniciais apresentavam sobreajuste ou subajuste. Esse diagnóstico orientou aumento do número de snapshots, revisão da normalização, ajuste de dimensão latente e separação temporal de treino e validação.

A etapa seguinte gerou o artigo *Redução de dimensionalidade em escoamento cavity via POD e SAE a partir de dados do OpenFOAM*, de Eldo Francisco Chagas Junior e Daniela de Oliveira Maionchi, publicado no congresso CBCFD. Nesse recorte, foram usados 1001 snapshots uniformes, $0 \leq t \leq 5$ s e $\Delta t = 0,005$ s, em uma malha de 1600 células. O vetor continha somente U_x e U_y , totalizando 3200 variáveis. A POD concentrou 68,59% da energia no primeiro modo, 95% em cinco modos e 99% em nove. O SAE com 16 latentes obteve $R^2 = 0,9954$ no treino e 0,9934 na validação, erro relativo médio de validação 0,0801 e menor perda de validação 0,0045. O artigo cumpriu a meta de comparar redução linear e não linear e deixou SINDy explicitamente como continuidade.

A etapa final executou essa continuidade e tornou o teste mais exigente: adicionou campos termodinâmicos e turbulentos, comparou quatro regimes e avaliou previsão autônoma. Os resultados posteriores da cavity não devem ser confrontados diretamente com os números do artigo como se fossem a mesma experiência. O conjunto final possui mais tempos, cinco canais, outro pré-processamento e uma divisão temporal distinta. A redução do R^2 do SAE final para 0,825 reflete, entre outros fatores, esse aumento da dimensionalidade física e o protocolo mais rigoroso, não uma correção dos resultados publicados.

4.2 Representação por POD

A Tabela 3 mostra que 50 modos representam bem todos os conjuntos, mas há ressalvas de proveniência. No dam-break laminar e no LES, k foi solicitado embora ausente e substituído por zero; no URANS salvo, a POD efetiva contém somente velocidade. Na cavidade, apresentam-se os números da execução corrigida.



UNIVERSIDADE FEDERAL DE MATO GROSSO
PRÓ-REITORIA DE PESQUISA
PROGRAMA INSTITUCIONAL DE INICIAÇÃO CIENTÍFICA

Tabela 3: Síntese dos resultados POD com 50 modos.

Caso	Snapshots	Energia	Erro relativo
Dam-break laminar	10001	0,9962	0,0617
Dam-break URANS	10001	0,9936	0,0802
Dam-break LES-WALE	1001	0,9936	0,0800
Cavity corrigida	5645	0,99988	0,01083




Figura 2: Energia e erro POD. Na cavidade usa-se a reexecução corrigida; nos dam-break permanecem as ressalvas de canais.

A POD é, portanto, eficiente para reconstrução. Isso não garante dinâmica: nos modelos SINDy, pequenas componentes e derivadas podem ser decisivas mesmo quando sua contribuição energética é baixa. A Figura 3 ilustra modos dominantes de dois casos.



UNIVERSIDADE FEDERAL DE MATO GROSSO
PRÓ-REITORIA DE PESQUISA
PROGRAMA INSTITUCIONAL DE INICIAÇÃO CIENTÍFICA




Figura 3: Primeiro modo POD multivariável.

4.3 Representação por SAE

O SAE não foi uniformemente superior à POD. O URANS dam-break apresentou a melhor generalização, enquanto os dois outros dam-break tiveram grande diferença entre treino e validação. No LES, a correção elevou R^2_{treino} de 0,585 para 0,989, mas R^2_{val} permaneceu 0,263. Isso caracteriza boa representação dos snapshots vistos e extrapolação temporal limitada.

Tabela 4: Síntese dos SAE usados ou corrigidos.

Caso	Latentes	R^2_{treino}	R^2_{val}	Erro L_2 val.
Dam-break laminar	8	0,822	0,133	0,918
Dam-break URANS	4	0,949	0,942	0,241
Dam-break LES corrigido	32	0,989	0,263	0,814
Cavity	8	0,809	0,825	0,392




Figura 4: Comparação do R^2 de reconstrução dos SAE. O LES corresponde à configuração corrigida; seus SINDy salvos ainda usam o latente antigo.

A vantagem teórica da variedade não linear depende de arquitetura, quantidade de dados, normalização e objetivo de treinamento. Minimizar apenas reconstrução não força suavidade temporal nem fechamento dinâmico.

4.4 Dinâmica identificada por SINDy

Os modelos diretos foram frágeis. POD–SINDy falhou em integração livre nos casos laminar, URANS e cavity corrigida; no LES integrou, mas com erro 1,652. SAE–SINDy falhou em todos os casos, apesar de erros guiados por vezes pequenos. Esses resultados confirmam que avaliação de derivadas ou de um passo não basta.



Tabela 5: Comparação dinâmica dos modelos SINDy.

Caso	POD–SINDy	SAE–SINDy	SAE–POD–SINDy	Interpretação
Laminar	livre falha	livre falha	erro 0,634; $R^2 = 0,598$	POD latente estabiliza, sem alta precisão
URANS	livre falha	livre falha	erro 0,551; $R^2 = 0,697$	melhor resultado global
LES–WALE	erro 1,652	livre falha	erro 0,858; $R^2 = 0,264$	estável, porém baixa fidelidade
Cavity	livre falha	livre falha	erro 0,644; $R^2 = 0,586$	campos diretos razoáveis, piora no final




Figura 5: Erro relativo e R^2 da integração livre SAE–POD–SINDy.

4.5 POD como estabilizador latente

O híbrido foi o único arranjo que completou integração livre nos quatro casos. A energia preservada pela POD latente foi 90,95% no laminar, praticamente 100% no URANS, 88,45% no LES e 96,68% na cavity. No URANS, a POD é equidimensional, aproximando o procedimento de estabilização do espaço latente descrito por Lin, Xiao e Fang [10]; nos demais casos há truncamento e, portanto, estabilização e filtragem ocorrem simultaneamente.



UNIVERSIDADE FEDERAL DE MATO GROSSO
PRÓ-REITORIA DE PESQUISA
PROGRAMA INSTITUCIONAL DE INICIAÇÃO CIENTÍFICA

O ganho deve ser interpretado com cautela. No laminar, todos os 32 coeficientes possíveis foram mantidos; no cavity, o modelo é mais esparso, com 11 de 40 termos. O LES tem o melhor ajuste local de derivadas, erro 0,187, mas o pior R^2 livre. Logo, bom ajuste local não determina estabilidade ou generalização global.




Figura 6: Campos decodificados pela integração livre do modelo híbrido.




Figura 7: Validação de campos nos casos mais desafiadores.



4.6 Auditoria da cavidade e validação corrigida

A POD legada da cavity continha α_{water} e p_{rgh} nulos. O resultado não havia sido copiado pronto: geometria, tempos e U, k eram da cavidade, mas o código era um template de dam-break adaptado parcialmente. A POD corrigida com U_x, U_y, p, T, k atingiu 99,303% da energia em 8 modos e 99,988% em 50. O POD–SINDy corrigido reduziu o erro de derivada para 0,0729, mas continuou incapaz de integração livre. Portanto, a inconsistência de campos prejudicava a análise, porém não era a única causa da instabilidade.

A comparação direta OpenFOAM–SAE–POD–SINDy mostrou, em $t = 1, 25; 2, 50; 3, 74; 5, 00$ s, erro de $|U|$ entre 0,128 e 0,245 e R^2 entre 0,757 e 0,958. Para k , o erro cresceu de 0,024 para 0,314, com R^2 ainda igual a 0,896 no final. Pressão e temperatura mantiveram a média, mas suas flutuações apresentaram R^2 baixo. A validação anterior, baseada em índice normalizado até 1 s, foi marcada como inválida.

4.7 Síntese científica

Os resultados sustentam quatro conclusões intermediárias. Primeiro, POD e SAE isolados medem capacidade de representação, não previsão. Segundo, a não linearidade do SAE não garante coordenadas dinamicamente simples. Terceiro, a POD latente melhora o condicionamento do SINDy de forma consistente, mas não elimina erro acumulado. Quarto, rastreabilidade de campos, tempos e artefatos é tão importante quanto a escolha do algoritmo: métricas numericamente boas podem ser produzidas por canais nulos, médias dominantes ou validações guiadas.



5. CONCLUSÃO

Em relação ao plano aprovado, foram concluídos a revisão bibliográfica, o treinamento no OpenFOAM e em bibliotecas Python, a geração e organização de dados em geometrias simplificadas, o desenvolvimento e a avaliação de POD/SAE, a identificação por SINDy, a interpretação comparativa e a divulgação científica. A progressão do relatório parcial ao artigo do CBCFD e, depois, aos quatro estudos finais evidencia a passagem de aprendizado e reconstrução para descoberta e validação dinâmica.

O objetivo de comparar modelos reduzidos foi atingido e ampliado. A POD mostrou-se uma referência robusta de compressão linear. O SAE capturou relações não lineares, mas sua generalização variou fortemente e não superou sistematicamente a POD. Os SINDy diretos apresentaram instabilidade em integração livre, demonstrando que ajuste local não comprova captura da dinâmica. O SAE-POD-SINDy foi a arquitetura mais robusta: todos os modelos selecionados completaram o intervalo, enquanto os SAE-SINDy falharam. O melhor resultado foi o dam-break URANS, com erro livre 0,551 e $R^2 = 0,697$; ainda assim, nenhum caso alcançou precisão suficiente para substituir a simulação de alta fidelidade sem ressalvas.

A hipótese de que a POD estabiliza o espaço latente foi confirmada qualitativamente. A transformação reduz correlação e direções ruidosas, favorecendo a regressão e a integração. Entretanto, quando há truncamento, o efeito mistura condicionamento e perda de informação. A relação com a modelagem ambiental permanece metodológica: os casos estudados representam bancos de prova controlados para técnicas que poderão ser transferidas a escoamentos atmosféricos, oceânicos ou de transporte, mas não constituem ainda uma simulação ambiental real.

Duas metas previstas permaneceram parciais: a análise paramétrica foi limitada à comparação entre laminar, URANS e LES, sem varredura sistemática, e as equações reduzidas não foram implementadas como um novo modelo no OpenFOAM. Também faltou realizar ajustes mais amplos nas arquiteturas e nos hiperparâmetros, incluindo profundidade e largura do autoencoder, dimensão e regularização do espaço latente, taxa de aprendizado, biblioteca de funções, limiares de esparsidade e parâmetros de integração do SINDy. Embora esses ajustes sejam necessários para buscar maior generalização e estabilidade, não foi possível concluir uma varredura abrangente dentro do período e dos recursos computacionais disponíveis.

A continuidade será realizada sobre os escoamentos microfluídicos controlados por microválvulas Tesla de Vieira [21]. Após validar malha, convergência e condições equivalentes nos sentidos direto e reverso, serão formados bancos de snapshots de



UNIVERSIDADE FEDERAL DE MATO GROSSO
PRÓ-REITORIA DE PESQUISA
PROGRAMA INSTITUCIONAL DE INICIAÇÃO CIENTÍFICA

velocidade e pressão para aplicar POD, SAE e SINDy. Pretende-se avaliar variações de número de Reynolds e geometria, relacionar as coordenadas reduzidas a vórtices, perda de carga e diodicidade e investigar modelos condicionados pela direção do fluxo. Paralelamente, deverão ser comparadas POD equidimensional e truncada, regularidade temporal do SAE, seleção da biblioteca SINDy por integração livre e inclusão de restrições físicas.



6. DIFICULDADES ENCONTRADAS

As principais dificuldades e ações corretivas foram:

1. **Alto custo e volume de dados.** Matrizes com até 10001 snapshots provocaram risco de falta de memória. Foram usados subamostragem, memmap e SVD aleatorizada truncada na correção da cavity.
2. **Generalização do SAE.** Taxa de aprendizado baixa, poucos snapshots e compressão excessiva prejudicaram o LES. A configuração foi alterada para 1001 snapshots, 32 latentes e taxa 10^{-3} , melhorando treino, embora a validação ainda seja limitada.
3. **Instabilidade do SINDy.** Integrações falharam por rigidez, biblioteca densa e coordenadas mal condicionadas. Foram testados Lasso/Adalasso, suavização, ordens diferentes e POD latente.
4. **Proveniência.** Notebooks atuais e modelos salvos nem sempre correspondem. Os relatórios distinguem configuração declarada, artefato executado e reexecução corrigida.

A divulgação científica ocorreu em etapas. O artigo do CBCFD apresentou apenas POD e SAE da prova de conceito da cavity, coerentemente com o estágio alcançado naquele momento, e anunciou SINDy como continuidade. A identificação dinâmica e a auditoria de dados foram desenvolvidas depois e, por isso, devem originar publicação posterior específica, sem alterar retrospectivamente o escopo do artigo já publicado.



7. REFERÊNCIAS BIBLIOGRÁFICAS

REFERÊNCIAS

- [1] BRUNTON, S. L.; KUTZ, J. N. *Data-Driven Science and Engineering: Machine Learning, Dynamical Systems, and Control*. Cambridge: Cambridge University Press, 2019. DOI: 10.1017/9781108380690.
- [2] BRUNTON, S. L.; PROCTOR, J. L.; KUTZ, J. N. Discovering governing equations from data by sparse identification of nonlinear dynamical systems. *Proceedings of the National Academy of Sciences*, v. 113, n. 15, p. 3932–3937, 2016. DOI: 10.1073/pnas.1517384113.
- [3] CORBETTA, M. Application of sparse identification of nonlinear dynamics for physics-informed learning. In: *IEEE Aerospace Conference*. Big Sky, 2020. NASA NTRS 20200001544. Disponível em: <https://ntrs.nasa.gov/citations/20200001544>. Acesso em: 28 set. 2026.
- [4] DÍAZ, N.; BARREIRO, M.; RUBIDO, N. Data driven models of the Madden–Julian Oscillation: understanding its evolution and ENSO modulation. *npj Climate and Atmospheric Science*, v. 6, art. 203, 2023. DOI: 10.1038/s41612-023-00527-8.
- [5] DIXIT, A.; KHAN, M. I.; AHMED, F.; BRUSEY, J. Learning from less: SINDy surrogates in reinforcement learning. *arXiv preprint arXiv:2504.18113*, 2025. Disponível em: <https://arxiv.org/abs/2504.18113>. Acesso em: 28 set. 2026.
- [6] HINTON, G. E.; SALAKHUTDINOV, R. R. Reducing the dimensionality of data with neural networks. *Science*, v. 313, n. 5786, p. 504–507, 2006. DOI: 10.1126/science.1127647.
- [7] HIRT, C. W.; NICHOLS, B. D. Volume of Fluid (VOF) method for the dynamics of free boundaries. *Journal of Computational Physics*, v. 39, n. 1, p. 201–225, 1981. DOI: 10.1016/0021-9991(81)90145-5.
- [8] KAISER, E.; KUTZ, J. N.; BRUNTON, S. L. Sparse identification of nonlinear dynamics for model predictive control in the low-data limit. *Proceedings of the Royal Society A*, v. 474, n. 2219, art. 20180335, 2018. DOI: 10.1098/rspa.2018.0335.
- [9] KAPTANOGLU, A. A. et al. PySINDy: a comprehensive Python package for robust sparse system identification. *Journal of Open Source Software*, v. 7, n. 69, art. 3994, 2022. DOI: 10.21105/joss.03994.
- [10] LIN, X.; XIAO, D.; FANG, F. Data discovery of low dimensional fluid dynamics of turbulent flows. *arXiv preprint arXiv:2401.05449*, 2024. Disponível em: <https://arxiv.org/abs/2401.05449>. Acesso em: 28 set. 2026.



UNIVERSIDADE FEDERAL DE MATO GROSSO
PRÓ-REITORIA DE PESQUISA
PROGRAMA INSTITUCIONAL DE INICIAÇÃO CIENTÍFICA

- [11] MÉNDEZ, M. A.; BRUNTON, S. L.; BUDIŠIĆ, M.; KAISER, E. *Data-Driven Fluid Mechanics: Combining First Principles and Machine Learning*. Cambridge: Cambridge University Press, 2023. DOI: 10.1017/9781108896214.
- [12] MENTER, F. R. Two-equation eddy-viscosity turbulence models for engineering applications. *AIAA Journal*, v. 32, n. 8, p. 1598–1605, 1994. DOI: 10.2514/3.12149.
- [13] NAOZUKA, G. T.; ROCHA, H. L.; SILVA, R. S.; ALMEIDA, R. C. SINDy-SA framework: enhancing nonlinear system identification with sensitivity analysis. *Nonlinear Dynamics*, v. 110, n. 3, p. 2589–2609, 2022. DOI: 10.1007/s11071-022-07755-2.
- [14] NICOUD, F.; DUCROS, F. Subgrid-scale stress modelling based on the square of the velocity gradient tensor. *Flow, Turbulence and Combustion*, v. 62, p. 183–200, 1999. DOI: 10.1023/A:1009995426001.
- [15] OPENFOAM FOUNDATION. *OpenFOAM version 13: user guide and source documentation*. 2025. Disponível em: <https://doc.cfd.direct/openfoam/user-guide-v13/>. Acesso em: 28 set. 2026.
- [16] PRITCHARD, P. J.; MITCHELL, J. W. *Fox and McDonald's Introduction to Fluid Mechanics*. 8. ed. Hoboken: Wiley, 2011.
- [17] REGIS, X.; JOHN MATHURAM, J.; PADIYARAJAN, V. Data cataloging based SINDy approach for weather forecasting. In: *2023 12th International Conference on Advanced Computing (ICoAC)*. IEEE, 2023. p. 1–5. DOI: 10.1109/ICoAC59537.2023.10249738.
- [18] RUDY, S. H.; BRUNTON, S. L.; PROCTOR, J. L.; KUTZ, J. N. Data-driven discovery of partial differential equations. *Science Advances*, v. 3, n. 4, e1602614, 2017. DOI: 10.1126/sciadv.1602614.
- [19] SIROVICH, L. Turbulence and the dynamics of coherent structures. I–III. *Quarterly of Applied Mathematics*, v. 45, n. 3, p. 561–590, 1987.
- [20] TU, J.; YEOH, G. H.; LIU, C. *Computational Fluid Dynamics: A Practical Approach*. Oxford: Butterworth-Heinemann, 2008.
- [21] VIEIRA, B. M. M. *Modelagem computacional de escoamentos microfluídicos controlados por microválvulas Tesla*. Relatório Final de Iniciação Científica, Universidade Federal de Mato Grosso, Cuiabá, 2025.
- [22] ZHONG, X.; JIANG, W.; ZHANG, J. TC-SINDy: improving physics-based deterministic tropical cyclone track and intensity model via data-driven sparse identification of nonlinear dynamics. *Journal of Wind Engineering and Industrial Aerodynamics*, v. 250, art. 105758, 2024. DOI: 10.1016/j.jweia.2024.105758.



8. PRODUTOS GERADOS

Os produtos refletem as etapas sucessivas do plano:

1. **Relatório parcial de iniciação científica**, referente a 30/10/2025–28/02/2026, com revisão, tutoriais OpenFOAM e resultados iniciais de POD/SAE em cavity e damBreakLaminarFine;
2. **artigo publicado no congresso CBCFD**: CHAGAS JUNIOR, Eldo Francisco; MAIONCHI, Daniela de Oliveira. *Redução de dimensionalidade em escoamento cavity via POD e SAE a partir de dados do OpenFOAM*. Trabalho de quatro páginas sobre a etapa de 1001 snapshots de velocidade;
3. quatro relatórios técnicos em LaTeX/PDF: dam-break laminar, dam-break URANS, dam-break LES–WALE e cavity URANS;
4. este relatório final consolidado, alinhado ao projeto, ao relatório parcial, ao artigo e ao modelo institucional da UFMT;
5. casos e dados OpenFOAM, notebooks e rotinas de POD, SAE, POD–SINDy, SAE–SINDy e SAE–POD–SINDy;
6. arquivos reproduzíveis com equações descobertas, métricas JSON/CSV/NPZ e figuras de comparação;
7. POD corrigida da cavity com U_x, U_y, p, T, k , rejeição explícita de snapshots incompletos e SVD truncada eficiente;
8. validador direto OpenFOAM–SINDy com alinhamento por tempo físico e documentação das inconsistências, artefatos legados e ações corretivas.

O arquivo disponibilizado do artigo não informa no texto extraído edição, local, páginas dos anais, DOI ou URL pública do CBCFD. Esses dados bibliográficos devem ser acrescentados à versão de submissão institucional caso constem no certificado ou nos anais do evento.